

Taller: Entropía Cruzada Binaria y Multiclase

Sistemas Inteligentes II

Estudiante: Sara Valentina Penagos Gamba

5 de septiembre de 2026

1. Entropía Cruzada Binaria

En clasificación binaria, suponga que la etiqueta verdadera es $y \in \{0, 1\}$ y que el modelo produce una salida $\hat{y} \in (0, 1)$, interpretada como $\hat{y} = P(y = 1|x)$.

La función de pérdida de entropía cruzada binaria se define como:

$$\mathcal{L}(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})].$$

1.1. Casos particulares (3 puntos)

Simplifique la expresión de $\mathcal{L}(y, \hat{y})$ en los dos casos posibles:

- Cuando $y = 1$.
- Cuando $y = 0$.

Explique brevemente qué probabilidad está siendo penalizada en cada caso.

Solución

a) **Cuando $y = 1$:**

$$\mathcal{L}(y, \hat{y}) = -[1 \cdot \ln(\hat{y}) + (1 - 1) \ln(1 - \hat{y})] = -\ln(\hat{y})$$

Interpretación: Se analiza la probabilidad de que el modelo prediga el valor real $y = 1$. Se penaliza que $\hat{y}$ esté lejos de 1. Si $\hat{y} \rightarrow 0$, la penalización crece hacia el infinito ($\mathcal{L} \rightarrow \infty$); mientras que si $\hat{y} \rightarrow 1$, la penalización tiende a 0.

b) **Cuando $y = 0$:**

$$\mathcal{L}(y, \hat{y}) = -[0 \cdot \ln(\hat{y}) + (1 - 0) \ln(1 - \hat{y})] = -\ln(1 - \hat{y})$$

Interpretación: Aquí encambio, se penaliza el complemento. Para que la penalización tienda a 0, se requiere que $(1 - \hat{y})$ esté cerca de 1, es decir, que $\hat{y}$ esté cerca de 0.

1.2. Cálculo e interpretación numérica (4 puntos)

Calcule la pérdida en los siguientes casos:

- $(y, \hat{y}) = (1, 0.9)$
- $(y, \hat{y}) = (1, 0.1)$
- $(y, \hat{y}) = (0, 0.9)$

- $(y, \hat{y}) = (0, 0.1)$

Luego responda:

- ¿En cuáles casos la pérdida es pequeña?
- ¿En cuáles casos la pérdida es grande?
- ¿Qué nos dice esto sobre la forma en que la entropía cruzada castiga predicciones confiadas pero equivocadas?

Solución

Considerando $y = 1$:

- Para $(y, \hat{y}) = (1, 0.9)$: $\mathcal{L} = -\ln(0.9) \approx 0.105$
- Para $(y, \hat{y}) = (1, 0.1)$: $\mathcal{L} = -\ln(0.1) \approx 2.303$

Considerando $y = 0$:

- Para $(y, \hat{y}) = (0, 0.9)$: $\mathcal{L} = -\ln(1 - 0.9) = -\ln(0.1) \approx 2.303$
- Para $(y, \hat{y}) = (0, 0.1)$: $\mathcal{L} = -\ln(1 - 0.1) = -\ln(0.9) \approx 0.105$

Preguntas de análisis

- ¿En cuáles casos la pérdida es pequeña?** En los aciertos, es decir, cuando la predicción del modelo está muy cerca del valor real y . Específicamente en $(1, 0.9)$ y $(0, 0.1)$.
- ¿En cuáles casos la pérdida es grande?** Cuando la predicción está muy lejos del valor real y . Específicamente en $(0, 0.9)$ y $(1, 0.1)$.
- ¿Qué nos dice esto sobre cómo castiga predicciones confiadas pero equivocadas?** No solo se castigan los errores, sino la confianza que tuvo el modelo al predecir. Un error con baja confianza se castiga mucho menos que un error con alta confianza (p. ej. predecir $\hat{y} = 0.1$ cuando $y = 1$). Esto se debe a la rapidez con la que crece la función logarítmica cuando su argumento se aproxima a cero.

1.3. Comportamiento en los extremos (3 puntos)

Analice qué ocurre con la pérdida cuando $\hat{y} \rightarrow 1$ y cuando $\hat{y} \rightarrow 0$ para cada uno de los casos $y = 1$ y $y = 0$.

Explique por qué la entropía cruzada penaliza fuertemente asignar probabilidad cercana a cero a la clase verdadera.

Solución

Como se observó en los cálculos:

- Para $y = 1$: Si $\hat{y} \rightarrow 0$, entonces $\mathcal{L} \rightarrow \infty$; si $\hat{y} \rightarrow 1$, entonces $\mathcal{L} \rightarrow 0$.
- Para $y = 0$: Si $\hat{y} \rightarrow 1$, entonces $\mathcal{L} \rightarrow \infty$; si $\hat{y} \rightarrow 0$, entonces $\mathcal{L} \rightarrow 0$.

En ambos casos, la pérdida depende de $-\ln(p)$, donde p es la probabilidad asignada a la clase correcta. Por la forma de la función logarítmica, la pérdida es extremadamente sensible cuando $p \rightarrow 0$ (se dispara al infinito), mientras que se reduce a cero cuando $p \rightarrow 1$.

1.4. Derivada respecto a la predicción (3 puntos)

Calcule:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}}$$

A partir del resultado, explique por qué la derivada puede crecer mucho cuando el modelo asigna una probabilidad muy baja a la clase correcta.

Solución

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{\partial}{\partial \hat{y}} \left(- [y \ln(\hat{y}) + (1 - y) \ln(1 - \hat{y})] \right) = -y \cdot \frac{1}{\hat{y}} + (1 - y) \cdot \frac{1}{1 - \hat{y}} = \frac{1 - y}{1 - \hat{y}} - \frac{y}{\hat{y}}$$

Unificando denominadores:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{\hat{y}(1 - y) - y(1 - \hat{y})}{\hat{y}(1 - \hat{y})} = \frac{\hat{y} - y\hat{y} - y + y\hat{y}}{\hat{y}(1 - \hat{y})} = \frac{\hat{y} - y}{\hat{y}(1 - \hat{y})}$$

¿Por qué la derivada puede crecer mucho cuando el modelo asigna una probabilidad baja a la clase correcta? Porque el denominador $\hat{y}(1 - \hat{y})$ tenderá a valores extremadamente pequeños (cerca de cero), lo cual hace que el cociente explote a un número muy grande. Esto coincide con el hecho de que la pendiente de la curva crezca aceleradamente en los extremos de error.

1.5. Sigmoid y señal de error (4 puntos)

Suponga ahora que la salida del modelo se obtiene aplicando una función sigmoid a un logit z :

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Usando la regla de la cadena, muestre que:

$$\frac{\partial \mathcal{L}}{\partial z} = \hat{y} - y.$$

Puede usar que:

$$\frac{d\sigma}{dz} = \sigma(z)(1 - \sigma(z)).$$

Finalmente, interprete el resultado $\hat{y} - y$. ¿Qué significa esta cantidad como señal de error en la capa de salida?

Solución

Dada la cadena de dependencias $z \rightarrow \hat{y} = \sigma(z) \rightarrow \mathcal{L}$, por regla de la cadena tenemos:

$$\frac{\partial \mathcal{L}}{\partial z} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z}$$

Sabiendo que la derivada de la función sigmoide es $\frac{\partial \sigma(z)}{\partial z} = \hat{y}(1 - \hat{y})$, sustituimos:

$$\frac{\partial \mathcal{L}}{\partial z} = \left(\frac{\hat{y} - y}{\hat{y}(1 - \hat{y})} \right) \cdot \hat{y}(1 - \hat{y}) = \hat{y} - y$$

Interpretación: La señal de error respecto a z simplifica directamente a la diferencia lineal $(\hat{y} - y)$. Si el modelo acierta, la resta tiende a cero (no hay nada que corregir); si se equivoca, el signo e intensidad indican la dirección y magnitud del ajuste. Además, al tratarse de probabilidades, el error queda acotado en el rango $[-1, 1]$, a diferencia de la derivada respecto a $\hat{y}$ que ya vimos.

2. Entropía Cruzada Multiclase

Considere ahora un problema de clasificación multiclase con K clases mutuamente excluyentes. La red produce un vector de logits:

$$z = (z_1, z_2, \dots, z_K)$$

La función softmax transforma estos logits en un vector de probabilidades:

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, \dots, K.$$

La etiqueta verdadera se representa mediante un vector one-hot $y = (y_1, y_2, \dots, y_K)$, donde $y_k \in \{0, 1\}$ y $\sum_{k=1}^K y_k = 1$.

La entropía cruzada categórica se define como:

$$\mathcal{L}(y, \hat{y}) = - \sum_{k=1}^K y_k \log(\hat{y}_k).$$

1.6. Softmax como vector de probabilidades (3 puntos)

Demuestre que la salida de softmax cumple $\hat{y}_k > 0$ para todo k , y que:

$$\sum_{k=1}^K \hat{y}_k = 1.$$

Explique por qué estas dos propiedades permiten interpretar $\hat{y}$ como una distribución de probabilidad sobre las clases.

Solución

Demostración:

1. Como la función exponencial es estrictamente positiva para cualquier valor real, $e^{z_k} > 0$ para todo k .
2. El denominador al ser una suma de exponenciales también es estrictamente positivo: $\sum_{j=1}^K e^{z_j} > 0$.
3. Por lo tanto, el cociente cumple:

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} > 0, \quad \forall k$$

4. Para la suma total:

$$\sum_{k=1}^K \hat{y}_k = \sum_{k=1}^K \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} = \frac{\sum_{k=1}^K e^{z_k}}{\sum_{j=1}^K e^{z_j}} = 1$$

Explicación: Estas propiedades garantizan que las salidas de la función Softmax puedan interpretarse formalmente como una *distribución de probabilidad* sobre las K clases: ninguna clase recibe probabilidad negativa y la probabilidad total asignada suma exactamente el 100 % (1).

1.7. Reducción a la clase correcta (3 puntos)

Suponga que la clase correcta es c . Entonces el vector one-hot cumple $y_c = 1$ y $y_k = 0$ para $k \neq c$.

Muestre que la pérdida se reduce a:

$$\mathcal{L}(y, \hat{y}) = -\log(\hat{y}_c).$$

Explique el significado de esta expresión en palabras.

Solución

Dada la pérdida multiclase $\mathcal{L}(y, \hat{y}) = -\sum_{k=1}^K y_k \ln(\hat{y}_k)$, siendo y un vector *one-hot* donde únicamente la clase real c tiene $y_c = 1$ y $y_k = 0$ para $k \neq c$:

$$\mathcal{L}(y, \hat{y}) = -[0 \cdot \ln(\hat{y}_1) + \dots + 1 \cdot \ln(\hat{y}_c) + \dots + 0 \cdot \ln(\hat{y}_K)] = -\ln(\hat{y}_c)$$

Significado: El cálculo de la pérdida ignora las probabilidades asignadas a las clases incorrectas y evalúa únicamente $\hat{y}_c$ (la probabilidad asignada a la clase verdadera). Si $\hat{y}_c \rightarrow 1$, la pérdida tiende a 0; si $\hat{y}_c \rightarrow 0$, la pérdida se dispara.

1.8. Cálculo e interpretación numérica (4 puntos)

Considere un problema con tres clases ($K = 3$). La clase correcta es la segunda, por lo que $y = (0, 1, 0)$.

Calcule la pérdida para las siguientes predicciones:

- $\hat{y}^{(A)} = (0.1, 0.8, 0.1)$
- $\hat{y}^{(B)} = (0.7, 0.1, 0.2)$
- $\hat{y}^{(C)} = (0.3, 0.4, 0.3)$

Luego ordene los tres casos de menor a mayor pérdida y explique el resultado.

Solución

Asumiendo que la clase correcta es la segunda ($c = 2$, es decir $y = [0, 1, 0]$):

- **Predicción A:** $\hat{y}^{(A)} = (0.1, 0.8, 0.1) \implies \mathcal{L} = -\ln(0.8) \approx 0.223$
- **Predicción B:** $\hat{y}^{(B)} = (0.7, 0.1, 0.2) \implies \mathcal{L} = -\ln(0.1) \approx 2.303$
- **Predicción C:** $\hat{y}^{(C)} = (0.3, 0.4, 0.3) \implies \mathcal{L} = -\ln(0.4) \approx 0.916$

Orden de pérdida (de menor a mayor): $\mathcal{L}^{(A)} < \mathcal{L}^{(C)} < \mathcal{L}^{(B)}$.

Este orden coincide inversamente con la probabilidad asignada a la clase real ($0.8 > 0.4 > 0.1$), lo cual demuestra que no importa cómo se distribuya la probabilidad entre las clases incorrectas, sino cuánta confianza se le otorgó a la clase verdadera.

1.9. Derivada guiada de softmax + entropía cruzada (5 puntos)

Queremos derivar la pérdida respecto a cada logit z_j . Partimos de:

$$\mathcal{L} = -\sum_{k=1}^K y_k \log(\hat{y}_k), \quad \text{con} \quad \hat{y}_k = \frac{e^{z_k}}{\sum_{r=1}^K e^{z_r}}$$

Primero muestre que:

$$\log(\hat{y}_k) = z_k - \log\left(\sum_{r=1}^K e^{z_r}\right)$$

Luego sustituya esta expresión en la pérdida y use que $\sum_{k=1}^K y_k = 1$.

A partir de ello, derive respecto a z_j y muestre que:

$$\frac{\partial \mathcal{L}}{\partial z_j} = \hat{y}_j - y_j.$$

Finalmente, escriba el resultado vectorial:

$$\nabla_z \mathcal{L} = \hat{y} - y.$$

Solución

Sustituyendo $\hat{y}_k = \frac{e^{z_k}}{\sum_{r=1}^K e^{z_r}}$ dentro de $\ln(\hat{y}_k)$:

$$\ln(\hat{y}_k) = z_k - \ln\left(\sum_{r=1}^K e^{z_r}\right)$$

Remplazando en la pérdida y usando $\sum_{k=1}^K y_k = 1$:

$$\mathcal{L} = -\sum_{k=1}^K y_k \left(z_k - \ln\left(\sum_{r=1}^K e^{z_r}\right) \right) = -\sum_{k=1}^K y_k z_k + \ln\left(\sum_{r=1}^K e^{z_r}\right)$$

Derivando respecto al *logit* z_j :

$$\frac{\partial \mathcal{L}}{\partial z_j} = -y_j + \frac{1}{\sum_{r=1}^K e^{z_r}} \cdot e^{z_j} = -y_j + \hat{y}_j = \hat{y}_j - y_j$$

En formato vectorial:

$$\nabla_z \mathcal{L} = \begin{pmatrix} \hat{y}_1 - y_1 \\ \vdots \\ \hat{y}_K - y_K \end{pmatrix} = \hat{y} - y$$

1.10. Interpretación de la señal de error multiclase (3 puntos)

Interprete el resultado $\hat{y} - y$. Explique qué ocurre:

- En la componente correspondiente a la clase correcta.
- En las componentes correspondientes a clases incorrectas.
- Cuando el modelo asigna mucha probabilidad a una clase equivocada.

Solución

- En la clase correcta** ($y_c = 1$): El gradiente es $\hat{y}_c - 1$. Dado que $\hat{y}_c \in (0, 1)$, el valor siempre será negativo. Cuanto más cerca esté $\hat{y}_c$ de 1, más cercana a cero será la corrección.
- En las clases incorrectas** ($y_k = 0, k \neq c$): El gradiente es $\hat{y}_k - 0 = \hat{y}_k > 0$. La magnitud del error es directamente proporcional a la probabilidad indebidamente asignada a esa clase falsa.

- c) **Cuando se asigna alta probabilidad a una clase equivocada:** La componente de la clase falsa genera una fuerte penalización positiva para reducir su logit z_k . Simultáneamente, al restar probabilidad a la clase verdadera, la componente $\hat{y}_c - 1$ genera una señal negativa de gran magnitud para impulsar el incremento de z_c . Ambos efectos se complementan para corregir el modelo.

2. Conexiones conceptuales con lo visto en clase (10 puntos)

Responda de manera argumentada. No se espera una respuesta extensa, pero sí precisa. Use fórmulas cuando le ayuden a sostener su argumento.

2.1. MSE, identidad y regresión (2 puntos)

Explique por qué la combinación **salida identidad + MSE** es natural para problemas de regresión. En su respuesta, aclare qué interpretación tiene la salida en regresión.

Solución

En regresión, $\hat{y}$ no representa una probabilidad ni pertenece a un rango acotado, sino que es una estimación directa de una cantidad real, como un precio o una temperatura, así que su rango natural es $\mathbb{R}$. Por eso la activación de salida más natural es la identidad, $\hat{y} = z$, que no restringe ni deforma ese rango (a diferencia de sigmoid o softmax, que comprimen la salida). Y como el error $y - \hat{y}$ ya vive en la misma escala que los datos, medirlo con MSE, $\ell(y, \hat{y}) = (y - \hat{y})^2$, es coherente, pues penaliza la distancia usual entre predicción y valor real sin necesitar ninguna transformación adicional.

2.2. Sigmoid, softmax y clasificación probabilística (2 puntos)

Compare brevemente **sigmoid + BCE** con **softmax + CCE**. Explique en qué tipo de problema se usa cada combinación y qué representa la salida del modelo.

Solución

Sigmoid + BCE se usa en clasificación **binaria**: la salida $\hat{y} = \sigma(z) \in (0, 1)$ representa una sola probabilidad, $P(y = 1 | x)$, y su complemento $1 - \hat{y}$ da la probabilidad de la otra clase. Softmax + CCE se usa en clasificación **multiclase** con K clases mutuamente excluyentes: la salida es un vector $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_K)$ que reparte la probabilidad entre todas las clases, con $\hat{y}_k > 0$ y $\sum_k \hat{y}_k = 1$. En ambos casos la salida es una probabilidad, pero sigmoid describe un único evento binario mientras que softmax describe una distribución completa sobre varias categorías que compiten entre sí.

2.3. Perceptrón frente a clasificación probabilística (2 puntos)

En el perceptrón, la salida es una decisión dura: $\hat{y} \in \{-1, +1\}$. En clasificación probabilística, la salida es una probabilidad.

Explique por qué esta diferencia permite construir funciones de pérdida diferenciables como la entropía cruzada, mientras que la regla del perceptrón se basa en una actualización correctiva cuando hay mala clasificación.

Solución

El perceptrón usa $\hat{y} = \text{sign}(w^\top x + b)$, una función escalonada cuya derivada es cero casi en todas partes y no está definida en el punto de quiebre (Capítulo 2 de las notas), así que no hay

una señal de gradiente útil: por eso Rosenblatt necesitó una regla correctiva que solo actualiza cuando $y_i \hat{y}_i \leq 0$, en lugar de minimizar una pérdida por descenso de gradiente. En cambio, en clasificación probabilística $\hat{y} = \sigma(z) \in (0, 1)$ es una función suave y monótona de z , con derivada $\sigma(z)(1 - \sigma(z))$ nunca nula, lo que permite construir una pérdida diferenciable como la entropía cruzada y propagar un gradiente informativo en cada punto. La diferencia clave es que la decisión dura descarta la magnitud de la confianza, mientras la salida probabilística conserva esa información continua, que es justo lo que necesita el descenso por gradiente.

2.4. Pérdida y optimizador no son lo mismo (2 puntos)

Explique la diferencia entre **función de pérdida** y **optimizador**. Use en su respuesta al menos dos de los siguientes términos: MSE, entropía cruzada, SGD, momentum, Adam.

2.4.1. Solución

La función de pérdida define **qué** significa equivocarse: es la superficie $J(\theta)$ que queremos reducir, por ejemplo MSE en regresión o entropía cruzada en clasificación. El optimizador define **cómo** recorrer esa superficie: decide qué desplazamiento hacer a partir del gradiente, por ejemplo SGD o Adam. Son decisiones independientes; podemos combinar entropía cruzada con SGD, MSE con Adam, o cualquier otra pareja compatible, porque cambiar la pérdida cambia la superficie a minimizar, mientras que cambiar el optimizador (SGD, momentum, Adam) cambia únicamente la forma de recorrerla, sin alterar qué es lo que se está minimizando.

2.5. Por qué la señal $\hat{y} - y$ es importante (2 puntos)

Tanto en el caso sigmoid + BCE como en softmax + CCE aparece una señal de salida de la forma $\hat{y} - y$ o, en forma vectorial, $\hat{y} - y$.

Explique por qué este resultado es importante para el entrenamiento de redes neuronales y cómo anticipa la idea de backpropagation.

2.5.1. Solución

Esta señal es importante porque, a pesar de que sigmoid+BCE y softmax+CCE parten de fórmulas distintas, al combinar la pérdida con su activación de salida correspondiente toda esa complejidad se cancela exactamente, dejando en ambos casos $\partial L / \partial z = \hat{y} - y$: una señal simple, acotada y nula solo cuando la predicción coincide con la etiqueta. Esto tiene que ver con el backpropagation porque $\hat{y} - y$ es justo la primera sensibilidad que hay que propagar hacia atrás a través de la red, el entrenamiento no necesita rederivar toda la pérdida en cada capa, solo necesita esta señal inicial en la salida. Que la señal de salida sea tan simple es lo que hace fácil manejar la regla de la cadena a través de una red profunda completa.